# BLM22535 – Makine Öğrenmesi Dersi Final Sunumu

**Grup Üyeleri:** Beyza Yılmaz(2321021036) – Erva Sara Özdal(2321021054) – Zehra Nur Özdoğan(2421021738)

## 1) Problem Tanımı ve Motivasyon

**a. Neden bu problem seçildi? Motivasyon nedir?**

- Günümüzde otonom araç teknolojileri ve gelişmiş sürücü destek sistemleri hızla yaygınlaşmaktadır. Bu sistemlerin güvenliği için trafik işaretlerinin doğru ve hızlı bir şekilde tanınması önemlidir. Gerçek dünya koşullarında trafik işaretlerini tespit etmek ve sınıflandırma problemini çözmeyi amaçlamaktayız.

**b. Seçilen problem sınıflandırma, regresyon ve kümeleme problemi mi?**

- Bu bir Çok Sınıflı Sınıflandırma (Multi-Class Classification) problemidir. Girdi olarak alınan trafik işareti görüntüsünün, önceden belirlenmiş 10 farklı sınıftan (Dur, Yaya Geçidi, Girilmez vb.) hangisine ait olduğu tahmin edilmeye çalışılmıştır.

**c. Bu çalışmanın amacı ve hedeflenen çıktı(lar) nedir?**

- Farklı eğitim mimarilerine sahip yöntemleri aynı veri seti üzerinden eğitip kıyaslayarak, doğruluk ve hız açısından en verimli modeli belirlemeyi amaçlamaktayız. %95 üzeri doğruluk oranına sahip, trafik levhalarını sınıflandırabilen bir model elde etmeyi hedeflemekteyiz.

## 2. Makine Öğrenmesi Yöntemleri

- **MobileNetV2 (CNN tabanlı) :** Görüntü işleme problemlerinde CNN (Evrişimli Sinir Ağları) en başarılı yöntemdir. MobileNetV2, özellikle mobil ve gömülü sistemler (Robotaksi gibi) için optimize edilmiş, az parametre ile yüksek performans veren hafif bir mimaridir.
- **XGBoost (Extreme Gradient Boosting):** Gradyan artırma tekniğiyle çalışan, yapılandırılmış verilerde yüksek başarı gösteren ağaç temelli bir yöntem olarak seçilmiştir.
- **Kıyaslama:** MobileNetV2, görüntüdeki mekansal özellikleri öğrenir. Karmaşık desenleri yakalar. Fakat eğitim süresi daha uzundur. XGBoos ise daha hızlı, yorumlanabilirliği yüksektir fakat görüntüdeki mekansal ilişkiyi kaybeder.

- **MobileNetV2:** PyTorch kütüphanesi kullanıldı. ‘torchvision.models’ üzerinden önceden eğitilmiş (pretrained) ağırlıklar yüklendi. Son katman (classifier), bizim 10 sınıfımıza uygun olacak şekilde ‘nn.Linear’ ile değiştirildi.
- **XGBoost:** ‘xgboost’ kütüphanesi kullanıldı. Görüntüler önce 16x16 boyutuna küçültüldü, ardından düzleştirilerek (flatten) 1 boyutlu vektör haline getirildi ve eğitildi.

- **MobileNetV2 için:** Learning Rate (Öğrenme oranı), Batch Size, Optimizer türü (Adam/SGD), Epoch sayısı, Dropout oranı.
- **XGBoost için:** max_depth (ağaç derinliği), eta (learning rate), subsample (örneklem oranı), num_boost_round(ağaç sayısı).

## 3. Deneysel Çalışmalar

- **Veri Kümesi:** Toplam 6155 adet eğitim görüntüsü kullanılmıştır. Her sınıf için en az 50 tane Google Haritalar üzerinden veri toplanıp etiketlenmiştir. Veri sayısını artırmak için Roboflow üzerinden verisetleri eklenip data augumantation uygulanmıştır.
- **Sınıflandırma Yapısı:** Veri kümesi; dur, girilmez, park yasak, yaya geçidi gibi 9 farklı trafik levhası sınıfını içerecek şekilde düzenlenmiştir.
- **Veri Bölütleme (Stratified Split):** Dengesiz dağılımı korumak için "Stratified" yöntem kullanıldı.
  - **Eğitim (Train):** 4135 örnek (%80)
  - **Doğrulama (Valid):** 517 örnek (%10)
  - **Test:** 517 örnek (%10)
- **Ön İşleme:**
    - **Cropping (Kırpma):** YOLO formatındaki etiket dosyalarından koordinatlar alınarak, büyük resimden sadece trafik işaretleri kırpıldı.
    - **Mapping (Haritalama):** Yanlış yazılmış veya benzer etiketler (örn: "saga-donulmez", "saga_donulmez") tek bir standart isme dönüştürüldü.
    - **Normalization: Piksel değerleri 0-255 aralığından 0-1 aralığına çekildi (**ToTensor**).**
    - **Resizing**
        1. MobileNetV2 için: 224x224 piksel.
        2. XGBoost için: 16x16 piksel (Hız ve hafıza optimizasyonu için).

- **Data Augumantation:**

Modelin genelleme yeteneğini artırmak ve farklı çevresel koşullara (farklı ışık, kamera açısı vb.) karşı dayanıklı olmasını sağlamak amacıyla Roboflow üzerinde aşağıdaki veri artırma teknikleri uygulanmıştır:

- **Döndürme (Rotation):** Kamera açısındaki olası eğiklikleri simüle etmek için görsellere ±15◦ döndürme uygulanmıştır.
- **Parlaklık (Brightness):** Farklı gün saatleri ve hava koşullarını (gölge, güneşli) modellemek amacıyla parlaklık değerlerinde ±%25 oranında değişim yapılmıştır.
- **Ölçeklendirme (Generation):** Her eğitim verisinden 3 farklı varyasyon üretilerek veri seti 3 katına çıkarılmıştır.
- *Not:* Trafik levhalarının yön bilgisi içermesi (örn: Sağa/Sola Dön) sebebiyle, modelin yanlış öğrenmesini engellemek adına **Yatay Çevirme (Horizontal Flip)** işlemi uygulanmamıştır.

- **Eğitim Adımları:**
  - **MobileNetV2:**
    - Optimizer: Adam
    - Learning Rate: 0.001
    - Batch Size: 32
    - Epoch: 20 .
    - Loss Function: CrossEntropyLoss.
  - **XGBoost:**
    - Objective: multi:softprob
    - Max Depth: 4 .
    - Eta: 0.2
    - Boost Rounds: 400.

## 4.Sonuçlar ve Karşılaştırma

- **CNN (MobileNetV2) grafiklerin yorumu**

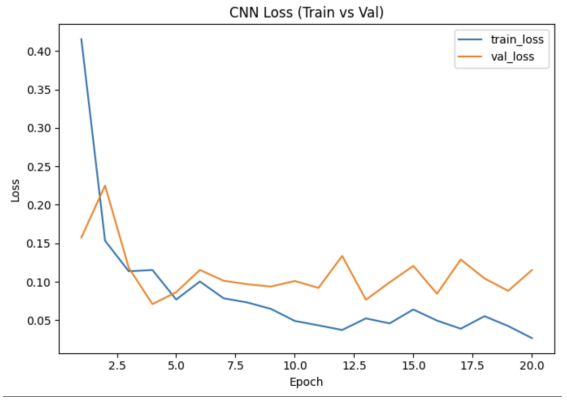


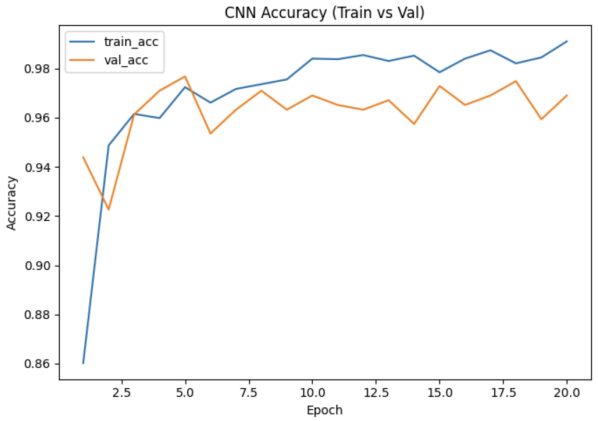


<u>CNN Loss grafiği</u>

train_loss düşüşte yaklaşık 0.42 -> 0.03
val_loss ilk başta düşüşte sonra dalgalanma var.
Model öğreniyor fakat bir yerden sonra trainde iyileşmeye devam ederken validation tarafı aynı hızda iyileşmiyor yani hafif overfitting var.

<u>CNN Accuracy grafiği</u>

Eğitim ve doğrulama doğruluk oranları birbirine paralel şekilde artmıştır. Transfer learning kullandığımız için model, çok erken epochlarda (henüz 3-4. epochta) %90 üzeri başarıya ulaşmıştır.

- **XGBoost grafikleri yorumu**

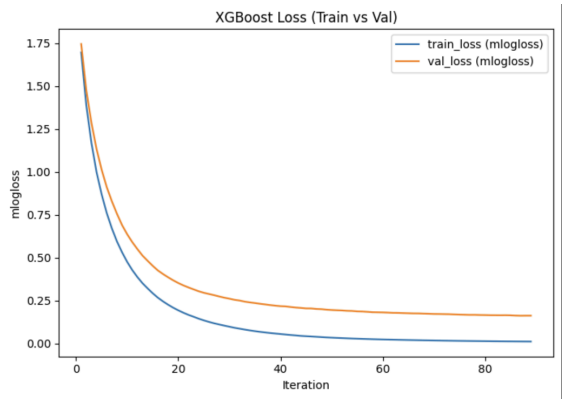


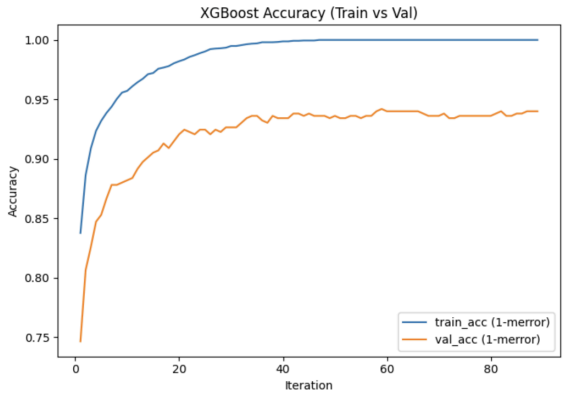


Grafikte görüldüğü üzere XGBoost, iterasyonlar ilerledikçe hatayı (logloss) hızla sıfıra yaklaştırmıştır. Eğitim verisi üzerindeki başarı %100'e ulaşmıştır. Doğrulama başarısı ise %95 civarındadır.

- **Model Performanslarının Karşılaştırılması**

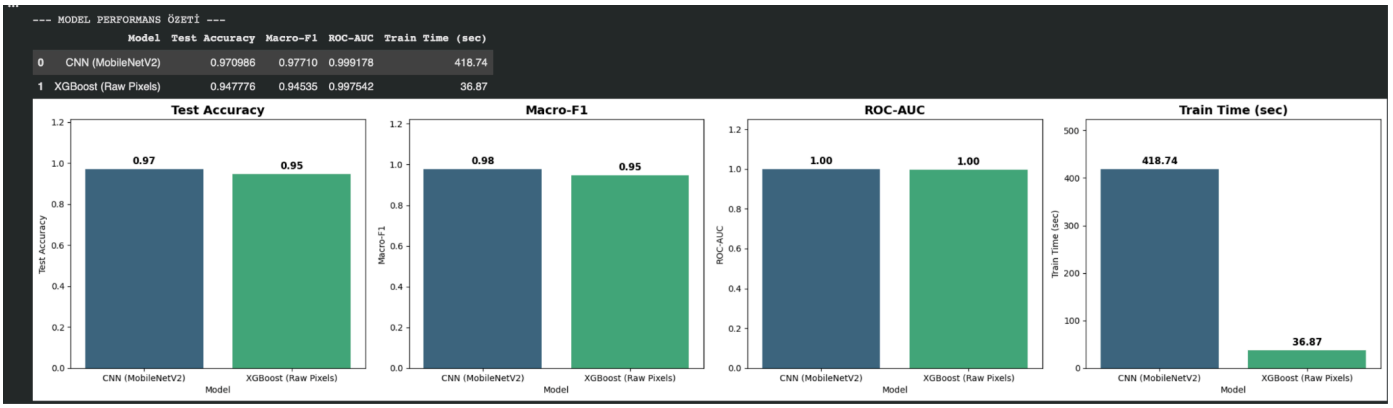

--- MODEL PERFORMANS ÖZETİ ---

| | Model | Test Accuracy | Macro-F1 | ROC-AUC | Train Time (sec) |
|---|---|---|---|---|---|
| 0 | CNN (MobileNetV2) | 0.970986 | 0.97710 | 0.999178 | 418.74 |
| 1 | XGBoost (Raw Pixels) | 0.947776 | 0.94535 | 0.997542 | 36.87 |



<u>Doğruluk (Accuracy) & F1-Skor:</u>

- MobileNetV2 (CNN): %97.09 başarı ile en yüksek performansı göstermiştir. Görüntüdeki mekansal özellikleri (şekil, kenar) koruduğu için daha başarılıdır.
- XGBoost: %94.77 başarı ile CNN'i çok yakından takip etmiştir. Ham piksel verisiyle çalışmasına rağmen bu kadar yüksek başarı elde etmesi, trafik işaretlerinin renk ve form olarak çok belirgin özniteliklere sahip olduğunu kanıtlar.

<u>ROC-AUC Skoru:</u>

- Her iki model de 1.00 ROC-AUC skoruna ulaşmıştır. Bu, modellerin sınıfları (örneğin "Dur" ile "Girilmez" levhasını) birbirinden ayırma yeteneğinin iyi olduğunu gösterir.

<u>Eğitim Süresi (Train Time):</u>

- Grafiğin sağ tarafında görüldüğü gibi; MobileNetV2'nin eğitimi GPU üzerinde 418 saniye sürerken, XGBoost sadece 36 saniyede eğitimi tamamlamıştır.
- Yorum: Eğer donanım kaynağımız sınırsızsa ve en yüksek doğruluk (güvenlik) hedefleniyorsa MobileNetV2 seçilmelidir. Ancak çok düşük güçlü bir işlemcide anlık sonuç isteniyorsa, %2'lik doğruluk kaybı göze alınarak 10 kat daha hızlı olan XGBoost kullanılabilir.